

LAPORAN PROJEK KELAS DEEP LEARNING

PREDIKSI HARGA PENUTUPAN EMITEN SAHAM YAHOO FINANCE DENGAN METODE *Long Short Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU)

**Adisya Ridia Nurahma ¹⁾, Mario Desendi Manurung ²⁾, Muhamad Syahid Burhanudien
Robbani ³⁾.**

Program Studi Sains Data, Jurusan Sains, Institut Teknologi Sumatera

Email : adisya.120450056@student.itera.ac.id ¹⁾, mario.120450082@student.itera.ac.id ²⁾
muhamad.120450092@student.itera.ac.id ³⁾

Abstrak

Penelitian ini mengembangkan model prediksi harga penutupan saham menggunakan metode LSTM dan GRU, dengan fokus pada saham BBKA. Hasil evaluasi menunjukkan bahwa prediksi GRU memiliki performa lebih baik dibandingkan LSTM, dengan MSE 2131, RMSE 46, dan MAPE 0.44, sedangkan LSTM memiliki MSE 2311, RMSE 48, dan MAPE 0.45. GRU terbukti efektif mengatasi fluktuasi tinggi pada data saham, memberikan informasi akurat untuk investor dan analis keuangan. Model diimplementasikan melalui antarmuka web menggunakan Streamlit, memungkinkan pengguna memilih model dan melakukan prediksi harga saham secara interaktif. Aplikasi Streamlit memberikan informasi komprehensif tentang performa model, mendukung pengambilan keputusan investasi yang lebih baik. Penelitian ini menghasilkan model prediksi yang akurat dan menyajikannya melalui aplikasi web interaktif, memberikan wawasan berharga bagi pemangku kepentingan di pasar saham.

Kata Kunci : GRU, LSTM, Prediksi, Saham

I. PENDAHULUAN

1.1 Latar Belakang

Saham merupakan salah satu aset keuangan yang paling populer di pasar modal. Terdapat beragam jenis investasi, dan salah satunya adalah berinvestasi di pasar modal. Pasar modal adalah tempat di mana berbagai jenis aset keuangan jangka panjang dapat diperdagangkan, termasuk surat utang, saham, dan instrumen keuangan lainnya. Harga saham pada dasarnya ditentukan oleh ketersediaan saham dan tingkat permintaan dari para investor. BCA diketahui selalu mengisi kolom indeks LQ45 pada Bursa Efek Indonesia atau BEI. Indeks LQ45 sendiri merupakan indeks terhadap saham-saham yang mendapatkan minat investor tertinggi berdasarkan kriteria-kriteria tertentu. Indeks LQ45 terdiri dari 45 emiten yang diurutkan berdasarkan likuiditas tertinggi.

LSTM dirancang untuk mengatasi keterbatasan yang ada pada RNN, yaitu kesulitan dalam memprediksi data berdasarkan informasi historis yang tersimpan dalam jangka waktu yang lebih panjang. LSTM, meskipun mampu mengatasi masalah penurunan gradien yang terjadi saat pelatihan pada Jaringan Saraf Rekuren (RNN), memiliki kompleksitas yang lebih tinggi dibandingkan dengan GRU. GRU hanya memiliki dua sigmoid dan satu tanh, sementara LSTM memiliki tiga sigmoid dan dua tanh. Secara teoretis GRU memiliki kemampuan pelatihan yang lebih cepat. Namun, perlu dicoba pada data dengan fluktuasi tinggi, seperti data saham untuk mendapatkan hasil yang optimal [4].

Penelitian ini memiliki beberapa manfaat yang mencakup pengujian kemampuan model LSTM dan GRU dalam memproses data saham blue chip Indonesia dengan jumlah data dan arsitektur tertentu. Untuk validasi hasil menggunakan MeanSquare Error (MSE), Root Mean Square Error (RMSE), Mean Absolute Error (MAE) dan skor R-squared (R^2).

Penelitian yang akan dilakukan yaitu perbandingan kinerja model deep learning Gated Recurrent Unit (GRU) dan Long Short-Term Memory (LSTM) dengan Prediksi Harga

Penutupan Emiten Saham. Penelitian ini dapat mengetahui perbandingan tingkat akurasi dari model terhadap Prediksi Harga Penutupan Emiten Saham.

1.2 Rumusan Masalah

1. Bagaimana perbandingan kinerja model deep learning Gated Recurrent Unit (GRU) dan Long Short-Term Memory (LSTM) dalam memprediksi harga penutupan saham?
2. Bagaimana nilai akurasi yang didapatkan dari kedua model dalam melakukan prediksi harga penutupan saham di pasar modal Indonesia?

1.3 Tujuan

1. Untuk mengevaluasi dan membandingkan kinerja model deep learning GRU dan LSTM dalam memprediksi harga penutupan saham.
2. Untuk menentukan tingkat akurasi masing-masing model dalam meramalkan harga penutupan saham di pasar modal, dengan tujuan memberikan wawasan yang lebih baik kepada para investor dan analis keuangan.

II. TINJAUAN PUSTAKA

2.1 Saham Yahoo Finance

Saham adalah representasi kepemilikan atau modal yang ditanamkan dalam suatu perusahaan. Apabila seseorang memperoleh saham, hal itu mencerminkan bagian dari kepemilikan perusahaan yang dimilikinya. Umumnya, saham diwakili dalam bentuk surat saham yang dikeluarkan oleh emiten, yaitu perusahaan terbatas [5].

Yahoo Finance merupakan sebuah platform yang menyajikan informasi mengenai harga saham, berita keuangan, alat manajemen portofolio, data pasar global, dan fitur interaksi sosial. Platform ini juga menyediakan data historis yang dapat digunakan untuk mendukung proses pengambilan keputusan dalam berinvestasi. Yahoo Finance merupakan bagian dari keluarga merek Yahoo, yang juga mencakup Yahoo dan AOL, serta layanan periklanan digitalnya, Yahoo Advertising.


2.2 Deep Learning

Deep Learning merupakan cabang dari Machine Learning yang terinspirasi dari kortek pada otak manusia dengan menerapkan jaringan syaraf tiruan yang memiliki banyak hidden layer. Deep learning telah meraih popularitas dan keberhasilan dalam beragam aplikasi, termasuk pengenalan gambar dan suara, pemrosesan bahasa alami, kendaraan otonom, analisis data besar, dan berbagai penggunaan lainnya. Teknik yang umum digunakan dalam deep learning mencakup Convolutional Neural Networks (CNN) untuk mengolah gambar, serta Recurrent Neural Networks (RNN), Long Short-Term Memory (LSTM), dan Gated Recurrent Unit (GRU) untuk mengelola data berurutan seperti teks dan suara. Deep learning memungkinkan mesin untuk secara otomatis mempelajari representasi yang semakin kompleks dan dalam dari data, suatu pencapaian yang tidak selalu bisa dicapai dengan metode pembelajaran mesin konvensional.

2.3 LSTM

Long Short Term Memory (LSTM) adalah perkembangan dari arsitektur Jaringan Saraf Rekuren (RNN), yang biasanya digunakan dalam konteks deep learning. LSTM yang dirancang oleh Hochreiter dan Schmidhuber pada tahun 1997, terdiri dari beberapa lapisan


LSTM yang menjalani proses secara berulang. Pada setiap modul LSTM, terdapat serangkaian operasi matematika seperti penjumlahan, perkalian, penggabungan, penggandaan vektor, serta penggunaan fungsi matematika seperti operasi tanh dan sigmoid. Yang membedakan LSTM dari Jaringan Saraf Rekuren (RNN) adalah bahwa LSTM tidak hanya meneruskan informasi ke depan, tetapi juga dapat menjaga dan mengakses informasi yang ada di lapisan sebelumnya [6].



Gambar 2.1. Perbandingan RNN dan LSTM

2.4 GRU

Gated Recurrent Unit (GRU) adalah salah satu tipe arsitektur dalam Jaringan Saraf Rekuren (RNN) yang digunakan dalam deep learning. Gated Recurrent Unit (GRU) pertama kali diperkenalkan oleh Cho dan rekannya pada tahun 2014 dengan tujuan untuk mengatasi permasalahan vanishing gradient yang terjadi dalam Jaringan Saraf Rekuren (RNN). Vanishing gradient problem adalah kondisi ketika nilai gradien menjadi semakin kecil seiring berjalannya waktu, dan ketika gradien ini sangat kecil, kontribusi terhadap pembelajaran (learning) menjadi minim. GRU memanfaatkan dua pintu (gate), yaitu Update Gate dan Reset Gate, untuk menentukan informasi mana yang akan diteruskan ke keluaran. Kedua komponen ini dapat dilatih untuk menyimpan informasi masa lalu tanpa harus menghapus informasi yang tidak relevan dengan proses prediksi [7].




Gambar 2.2. Diagram GRU

2.6 Streamlit

Streamlit ialah sebuah kerangka kerja berbasis Python yang bersifat open-source, dirancang untuk menyederhanakan proses pembuatan aplikasi web interaktif di bidang data sains dan Machine Learning. Keunikan dari kerangka kerja ini terletak pada kemampuannya untuk mengurangi kebutuhan pengetahuan tentang desain situs web menggunakan CSS, HTML, dan JavaScript. Dalam penggunaan Streamlit, hanya diperlukan pengetahuan dasar dalam bahasa pemrograman Python.

III. METODE

3.1 Diagram Alir



Gambar 3.1 Diagram alir

3.2 Pengumpulan Data

Pengumpulan data adalah langkah awal dalam penelitian ini. Data harga penutupan saham diperoleh melalui layanan Yahoo Finance menggunakan pustaka yfinance. Data ini mencakup harga penutupan saham harian selama periode tersebut. Data historis ini adalah dasar dari analisis dan prediksi yang akan dilakukan.

3.3 Preprocessing

Pertama dilakukan Visualisasi data. Visualisasi data adalah tahap awal yang penting dalam pemahaman tren dan pola yang ada dalam data harga penutupan saham yahoo finance. Plot utama dengan empat garis plot (Opening Price, Closing Price, Low Price, dan High Price) memberikan gambaran umum tentang bagaimana harga saham berfluktuasi sepanjang waktu. Ini membantu dalam mengidentifikasi tren umum, volatilitas, dan pola pergerakan harga saham dari 2019-2023.



Gambar 3.2 Plot Stock Price History

Selanjutnya, membagi plot utama menjadi empat bagian. Masing-masing bagian subplot menampilkan grafik untuk harga pembukaan, penutupan, rendah, dan tinggi. Subplot ini memberikan pemahaman yang lebih rinci tentang perubahan harga saham sepanjang waktu.



Gambar 3.3 Subplot Stock Price

Grafik ini membantu dalam memahami bagaimana harga saham berfluktuasi dari hari ke hari dan dapat memberikan wawasan tentang perubahan harga. Harga Saham BBKA meningkat secara signifikan dari tahun ke tahun, tetapi sempat menurun pada tahun 2020.

Tahap Selanjutnya, terdapat fungsi `prepare_data(data, n_steps)` yang digunakan untuk mempersiapkan data dengan melibatkan lag values. Lag values ini merupakan nilai-nilai sebelumnya dalam rentang waktu tertentu (ditentukan oleh `n_steps`). Fungsi ini menghasilkan dua array, `X` dan `y`, yang akan digunakan sebagai input dan output model.

Selanjutnya, dengan menggunakan nilai `n_steps` sebesar 120, data yang sudah dinormalisasi (`scaled_data`) diolah menggunakan fungsi `prepare_data`. Hasilnya adalah dua array, `X` dan `y`, yang masing-masing berisi sekumpulan lag values dan nilai target. Proses ini dilakukan untuk setiap interval waktu yang mungkin, sehingga terbentuk dataset yang sesuai dengan kebutuhan model. Selanjutnya, dataset dibagi menjadi dua bagian, yaitu data pelatihan (`train`) dan data pengujian (`test`). Pembagian ini dilakukan dengan mengambil 80% data sebagai data pelatihan dan 20% sisanya sebagai data pengujian.

Kemudian, dilakukan reshaping pada data untuk mengakomodasi input yang dibutuhkan oleh model LSTM dan GRU. Data `train` dan `test` diubah dimensinya menjadi tiga dimensi, yaitu (jumlah sampel, jumlah time steps, jumlah fitur) dengan fitur dalam hal ini hanya satu (nilai tutup saham).

Dengan langkah-langkah ini, data sudah siap untuk digunakan dalam pelatihan model LSTM dan GRU, di mana setiap sampel akan memiliki informasi historis dari 120 time steps sebelumnya. Proses ini penting untuk memastikan model dapat memahami pola dan hubungan dalam data time series dengan baik.

3.4 Hyper Parameter Tuning

Pertama, sebuah ruang pencarian (`search space`) untuk hyperparameter didefinisikan dalam bentuk dictionary yang disebut `space`. Hyperparameter yang dioptimalkan melibatkan beberapa parameter kunci sebagai berikut:

- 'units': Jumlah unit/neuron dalam layer LSTM atau GRU. Pilihan yang mungkin adalah 50, 100, atau 150.
- 'dropout_rate': Tingkat dropout, yaitu proporsi unit yang akan di-dropout selama pelatihan. Rentang nilai diatur antara 0.2 dan 0.5.
- 'learning_rate': Tingkat pembelajaran, yang menentukan seberapa besar langkah yang diambil selama proses pembelajaran. Nilai ini diambil dari distribusi loguniform antara $\log(0.001)$ dan $\log(0.01)$.
- 'epochs': Jumlah epoch, yaitu berapa kali seluruh dataset akan digunakan dalam proses pelatihan. Pilihan yang mungkin adalah 50, 100, atau 150.
- 'batch_size': Ukuran batch, yaitu berapa banyak sampel yang digunakan dalam satu iterasi pelatihan. Pilihan yang mungkin adalah 32, 64, atau 128.

Selanjutnya, callback untuk early stopping (`early_stopping`) juga didefinisikan. Early stopping digunakan untuk menghentikan pelatihan lebih awal jika tidak terjadi peningkatan kinerja model pada data validasi dalam beberapa epoch (sesuai dengan parameter `patience`).

Proses hyperparameter tuning selanjutnya akan menggunakan fungsi objektif yang mencoba meminimalkan mean squared error (MSE) pada data validasi. Proses ini akan dilakukan secara otomatis oleh Hyperopt, yang akan menjelajahi ruang pencarian dan menguji berbagai kombinasi hyperparameter untuk menemukan kombinasi terbaik yang menghasilkan kinerja model terbaik pada data validasi.

3.5 Model Building

Dua jenis model rekaman jangka pendek (RNN) digunakan: LSTM dan GRU. LSTM (Long Short-Term Memory) dan GRU (Gated Recurrent Unit) adalah dua jenis arsitektur RNN yang dapat menangani masalah prediksi deret waktu dengan baik. Kedua model ini memiliki beberapa lapisan rekaman untuk mengambil informasi dari data sebelumnya. Model LSTM terdiri dari tiga lapisan LSTM, sementara model GRU juga terdiri dari tiga lapisan GRU. Selain lapisan rekaman, ada lapisan Dense yang digunakan untuk menghasilkan output prediksi.

Pertama, sebuah fungsi bernama `objective` didefinisikan untuk membangun dan melatih model dengan hyperparameters tertentu. Fungsi ini memanfaatkan library TensorFlow melalui Keras untuk membuat model sequential dengan layer-layer LSTM atau GRU sesuai dengan jenis model yang diinginkan. Model ini kemudian dikompilasi dengan menggunakan optimizer Adamax dan fungsi loss berupa mean squared error. Selama pelatihan, callback early stopping juga digunakan untuk menghentikan pelatihan lebih awal jika tidak terjadi peningkatan kinerja model pada data validasi. Fungsi ini mengembalikan nilai mean squared error (MSE) dan riwayat pelatihan.

Selanjutnya, objek `Trials` digunakan untuk melacak proses optimasi hyperparameter. Proses optimasi dilakukan menggunakan fungsi `fmin` dari library Hyperopt. Proses ini dijalankan terpisah untuk model LSTM (`trials_lstm`) dan model GRU (`trials_gru`). Hasil optimasi berupa hyperparameters terbaik untuk masing-masing model diambil menggunakan fungsi `space_eval`.

Setelah mendapatkan hyperparameters terbaik, model LSTM dan GRU final dibangun menggunakan hyperparameters tersebut. Kedua model ini kemudian dikompilasi dan dilatih menggunakan data pelatihan. Proses pelatihan ini juga melibatkan callback early stopping untuk menghindari overfitting.

Riwayat pelatihan dari kedua model disimpan dalam variabel `history_lstm` dan `history_gru`. Informasi ini dapat digunakan untuk menganalisis kinerja model selama proses pelatihan, seperti kurva loss pada set pelatihan dan validasi. Dengan mengeksekusi kode, akan mendapatkan dua model terlatih (`final_model_lstm` dan `final_model_gru`) yang siap digunakan untuk membuat prediksi pada data baru.

3.6 Evaluasi Model

Setelah pelatihan, model-model LSTM dan GRU dievaluasi menggunakan data pengujian. Evaluasi dilakukan dengan menghitung beberapa metrik, termasuk Mean Squared Error (MSE), Root Mean

Squared Error (RMSE), dan Mean Absolute Percentage Error (MAPE). Metrik-metrik ini membantu menilai sejauh mana model dapat memprediksi harga penutupan saham dengan

akurat. Selain itu, prediksi dari model-model tersebut diubah kembali menjadi skala asli (inverse transform) untuk membandingkannya dengan data pengujian.

Pertama, untuk model LSTM, dilakukan prediksi terhadap data uji (`X_test_lstm`). Hasil prediksi kemudian diubah kembali ke skala asli menggunakan objek scaler. Selanjutnya, dihitung sejumlah metrik evaluasi performa model seperti Mean Squared Error (MSE), Root Mean Squared Error (RMSE), dan Mean Absolute Percentage Error (MAPE). Hasil evaluasi ini kemudian ditampilkan dalam bentuk teks menggunakan fungsi `print`.

Proses evaluasi yang serupa juga dilakukan untuk model GRU dengan menggunakan data uji yang sesuai (`X_test_gru`). Metrik evaluasi yang dihitung mencakup MSE, RMSE, dan MAPE, yang juga ditampilkan menggunakan `print`. Setelah itu, dilakukan visualisasi prediksi menggunakan library `Plotly`. Dua garis waktu digambarkan: satu untuk harga saham aktual dan dua lainnya untuk prediksi harga saham menggunakan model LSTM dan GRU. Grafik ini memberikan pemahaman visual tentang sejauh mana prediksi model mendekati harga saham aktual.

Terakhir, menggunakan `Matplotlib`, dilakukan plot dari riwayat pelatihan untuk kedua model. Masing-masing subplot menunjukkan perubahan nilai loss selama pelatihan pada set pelatihan dan validasi. Grafik ini membantu dalam mengevaluasi apakah model mengalami overfitting atau underfitting selama pelatihan.

Dengan menjalankan seluruh code ini, dapat memeriksa dan menganalisis secara komprehensif kinerja model LSTM dan GRU, serta memahami sejauh mana model tersebut efektif dalam memprediksi harga saham berdasarkan metrik evaluasi dan visualisasi yang diberikan.

3.7 Save Model

Selanjutnya dilakukan , proses menyimpan dan mengunduh model LSTM dan GRU setelah proses pelatihan. Pertama, model LSTM yang telah dilatih (`final_model_lstm`) disimpan dalam format berkas `HDF5` menggunakan fungsi `save` dengan nama berkas "`final_model_lstm.h5`". Selanjutnya, menggunakan `files.download`, berkas tersebut diunduh

secara otomatis ke perangkat lokal pengguna. Proses serupa juga dilakukan untuk model GRU. Model GRU (`final_model_gru`) disimpan sebagai berkas "`final_model_gru.h5`" dan diunduh ke perangkat lokal pengguna.

Penting untuk dicatat bahwa pengguna perlu memastikan bahwa mereka menjalankan kode ini di lingkungan Google Colab, karena fungsi `files.download` dan beberapa operasi penyimpanan model dapat bervariasi tergantung pada lingkungan pengembangan yang digunakan. Dengan menjalankan code ini, pengguna dapat dengan mudah menyimpan model yang telah dilatih dan mengunduhnya untuk penggunaan selanjutnya di luar lingkungan Google Colab.

3.8 Deploy

Setelah dilakukan Evaluasi Model dan Save Model, Selanjutnya dilakukan tahap deploy aplikasi, menggunakan streamlit. Setelah aplikasi Streamlit dijalankan, kode terakhir bertujuan untuk menginstall Streamlit secara diam-diam (`!pip install streamlit -q`), menampilkan alamat IP menggunakan LocalTunnel (`!wget -q -O - ipv4.icanhazip.com`), dan menjalankan aplikasi Streamlit menggunakan perintah (`! streamlit run app.py & npx localtunnel --port 8501`).

Dengan langkah terakhir tersebut, aplikasi Streamlit dapat diakses melalui tautan yang dihasilkan oleh LocalTunnel. Ini memungkinkan pengguna untuk berinteraksi dengan aplikasi prediksi harga saham melalui browser web.

IV. HASIL PEMBAHASAN

4.1 Hasil

Hasil dari prediksi model LSTM dan GRU setelah dilakukan normalisasi *min-max scaler* mengubah rentang nilai saham dari 0 hingga 1 dan menggunakan *window size* sepanjang 120 hari dan diikuti dengan nilai lag sebesar nilai *window size* ditambah nilai data, setelah itu dilakukan pemisahan data menjadi data train dan data testing dengan komposisi sebagai berikut yaitu 80% data training dan 20% data testing, kemudian dilakukan hyperparameter search tuning dengan parameter sebagai berikut:

Parameter	Value
units	50, 100, 150
dropout_rate	0.2, 0.5
learning_rate	0.001, 0.01
epochs	50, 100, 150
batch_size	32, 64, 128

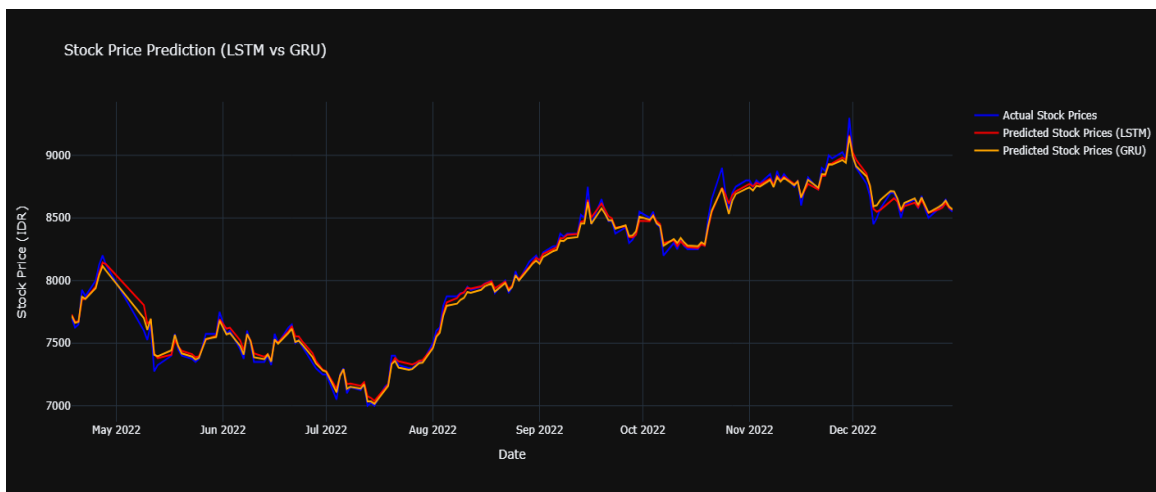
Didapatkan hasil menggunakan *hyperparameter tuning search space* dengan *best hyperparameters* untuk kedua model. Kemudian setelah itu dilakukan pemodelan untuk kedua model menggunakan *best hyperparameter* yang sudah didapatkan melalui proses *tuning* dan melakukan pemodelan LSTM dan GRU. Terakhir akan dilakukan *plot history* untuk melihat apakah data *overfitting* maupun *underfitting*.

Prediksi kedua model dengan metode LSTM dan juga metode GRU, menghasilkan hasil MSE, RMSE, MAPE sesuai dengan pada tabel 4.1. Hasil yang didapatkan dari perbandingan kedua model LSTM dan GRU. MSE, RMSE, MAPE, secara berurutan model prediksi yang memiliki akurasi tertinggi adalah model GRU dengan hasil *error* yang lebih kecil

dibandingkan dengan model prediksi LSTM yang dapat dilihat pada Gambar 4.1 mengenai prediksi dari model LSTM dan GRU.

Tabel 4.1 Hasil MSE, RMSE, MAPE Model LSTM dan GRU

Model	MSE	RMSE	MAPE
LSTM	2311	48	0.45231714697347236
GRU	2131	46	0.4413840232921354



Gambar 4.1. Grafik prediksi model LSTM dan GRU untuk emiten saham Bank BCA (IDX:BBCA)

4.2 Tahapan Deployment

Penelitian ini menghadirkan langkah-langkah yang terperinci dalam merancang dan melaksanakan tahapan deployment model prediksi harga saham. Proses ini dimulai dengan menghasilkan dua model akhir yang signifikan, yaitu 'final_model_gru.h5' dan 'final_model_lstm.h5', yang mewakili inti dari analisis dan pembelajaran mendalam yang telah dilakukan. Pentingnya tahap ini tidak dapat diabaikan, mengingat model-model ini menjadi landasan utama dalam memberikan prediksi harga saham yang akurat.

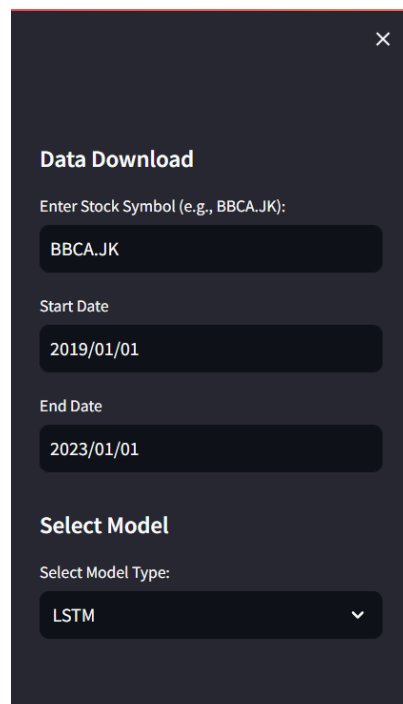
Selanjutnya, fokus penelitian berpindah ke pengembangan antarmuka pengguna melalui file 'app.py'. Antarmuka pengguna ini dirancang tidak hanya sebagai wadah untuk model, tetapi juga sebagai alat interaktif yang memungkinkan pengguna untuk dengan mudah menjelajahi

dan memanfaatkan hasil prediksi. Proses ini menegaskan komitmen untuk memberikan pengalaman pengguna yang intuitif dan efisien.

Setelah antarmuka pengguna selesai dibuat, penelitian melangkah ke tahap uji coba deployment di lingkungan lokal. Uji coba ini menjadi langkah kritis untuk memastikan bahwa model dan antarmuka pengguna berinteraksi secara mulus dan responsif. Hasil positif dari uji coba ini menjadi dasar kepercayaan untuk melanjutkan ke tahap deployment pada layanan Streamlit atau platform cloud lainnya.

Langkah akhir penelitian ini adalah membuka akses global terhadap model prediksi dan antarmuka pengguna. Dengan demikian, penelitian ini bukan hanya menghasilkan model yang kuat secara prediktif, tetapi juga membuktikan kehandalan dalam menyajikan informasi kepada pengguna dengan cara yang inovatif dan dapat diakses secara luas. Sehingga, hasil penelitian ini memiliki dampak praktis yang signifikan dalam mendukung pengambilan keputusan terkait investasi di pasar saham.

4.3 Tampilan *Deployment*

The image shows a dark-themed web application interface. At the top right is a close button (X). The main content is divided into two sections. The first section, titled "Data Download", contains three input fields: "Enter Stock Symbol (e.g., BBKA.JK):" with the value "BBKA.JK", "Start Date" with the value "2019/01/01", and "End Date" with the value "2023/01/01". The second section, titled "Select Model", contains a dropdown menu labeled "Select Model Type:" with the selected option "LSTM".

Gambar 4.2. Tampilan Bilah Sampling

4.3.1 Tampilan Bilah Samping

Tampilan bilah samping dari deployment yang dilakukan pada website streamlit berisikan *Data Download*, *Enter Stock Symbol*, *Start Date*, *End Date*, dan *Select Model*.

A. Data Download

Pada tampilan awalan yaitu *data download* yang berisikan *Enter Stock Symbol* (cth. BBKA.JK) adalah suatu tampilan yang dapat diubah dengan menambahkan input data baru dengan mengubah kode emiten pada *yahoo finance*.

B. Start Date

Tampilan *Start Date* ini merupakan tampilan untuk menambahkan tanggal awalan prediksi untuk saham yang sudah diunduh menggunakan tampilan *Data Download*.

C. End Date

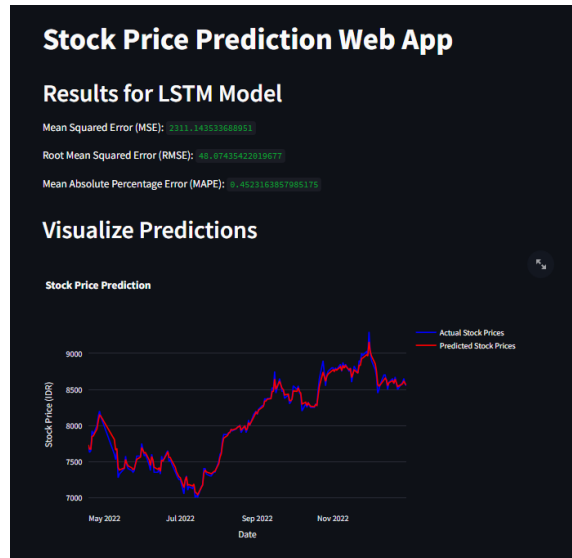
Tampilan *End Date* ini merupakan tampilan untuk menambahkan tanggal awalan prediksi untuk saham yang sudah diunduh menggunakan tampilan *Data Download*.

D. Select Model

Pada tampilan bilah samping berikut adalah untuk memilih model yang akan digunakan untuk memprediksi data dari tanggal awalan hingga tanggal akhir yang akan ditentukan, model yang dapat dipilih adalah LSTM dan GRU.

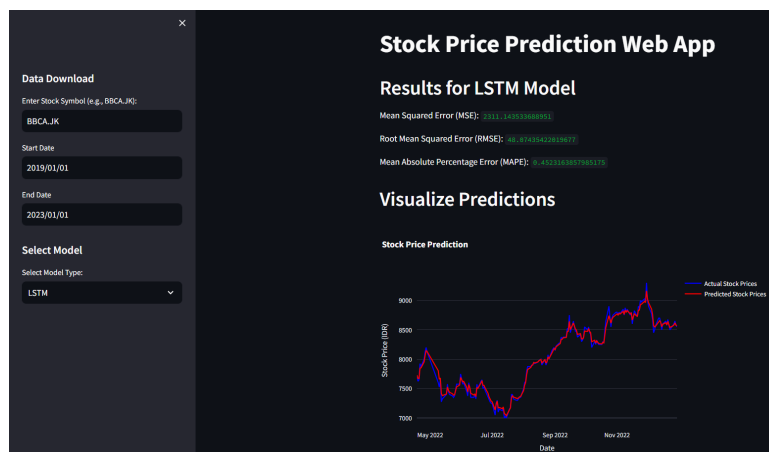
E. Tampilan Bilah Utama

Tampilan pada bilah utama menampilkan akurasi dari model yang akan memprediksikan data, metrik evaluasi yang digunakan sebagai akurasi yaitu *mean squared error* (mse), *root mean squared error* (rmse), *mean absolute percentage error* (mape). Tampilan pada bilah utama juga menampilkan visualisasi prediksi setelah serangkaian proses dilakukan, tampilan itu akan menampilkan hasil prediksi dan hasil asli dari data secara *real-time*.



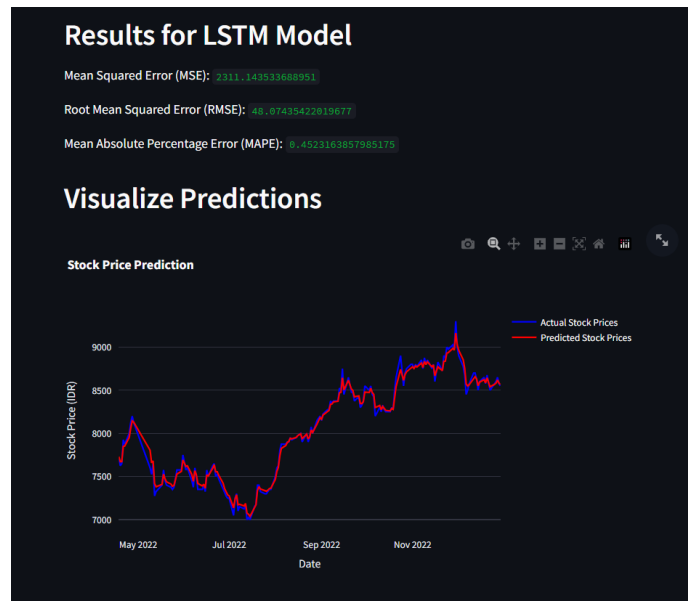
Gambar 4.3 Tampilan Bilah Utama

Dalam penelitian kami tentang prediksi harga penutupan emiten saham *yahoo finance* dengan metode *Long-short-term-memory* (LSTM) dan *Gated Recurrent Unit* (GRU) pada gambar 4.3 menunjukkan sebuah halaman website hasil dari model kami yang mampu memberikan evaluasi dan visualisasi yang baik untuk digunakan memprediksi saham. Pada gambar 4.4 menampilkan tampilan penuh dari *deployment streamlit*.



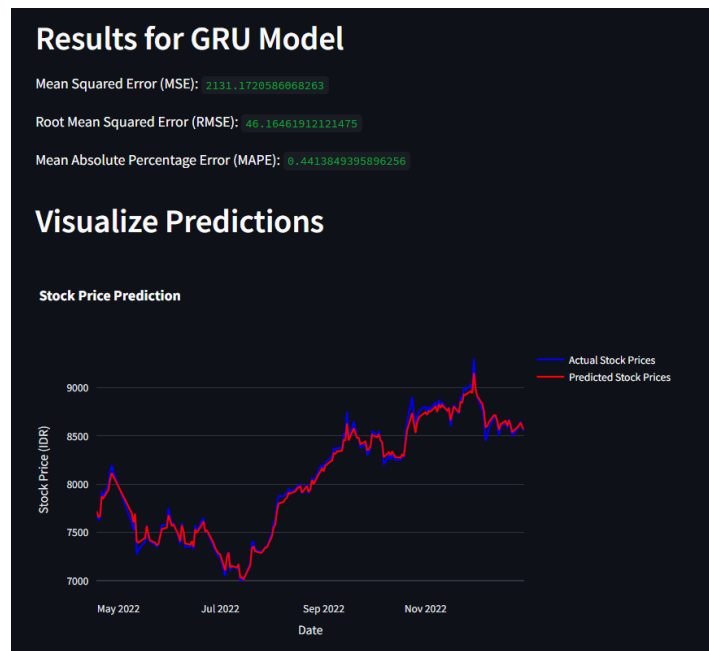
Gambar 4.4 Tampilan Penuh *Streamlit*

4.4 Prediksi dalam Web-App



Gambar 4.5 Prediksi Saham BBCA LSTM Model

Pada gambar 4.5 dilakukan prediksi saham BBCA menggunakan metode LSTM dengan hasil MSE sebesar 2311, RMSE 48, dan MAPE sebesar 0.45.



Gambar 4.6 Prediksi Saham BBCA GRU Model

Pada gambar 4.6 dilakukan prediksi saham BBCA menggunakan metode GRU dengan hasil MSE sebesar 2131, RMSE 46, dan MAPE sebesar 0.44.

KESIMPULAN

Penelitian ini mengembangkan model prediksi harga penutupan saham menggunakan metode LSTM dan GRU. Hasil yang didapatkan dalam prediksi saham BBKA menggunakan metode LSTM mendapatkan hasil MSE sebesar 2311, RMSE 48, dan MAPE sebesar 0.45 dan prediksi saham BBKA menggunakan metode GRU mendapatkan hasil MSE sebesar 2131, RMSE 46, dan MAPE sebesar 0.44.

Hasil evaluasi menunjukkan GRU memiliki performa lebih baik dengan nilai MSE, RMSE, dan MAPE yang lebih rendah daripada LSTM. Prediksi GRU efektif mengatasi fluktuasi tinggi pada data saham, memberikan informasi akurat untuk investor dan analis keuangan. Model diimplementasikan melalui antarmuka web menggunakan Streamlit, memungkinkan pengguna memilih model dan melakukan prediksi harga saham secara interaktif. Tampilan aplikasi Streamlit memberikan informasi komprehensif tentang performa model, mendukung pengambilan keputusan investasi yang lebih baik. Penelitian ini tidak hanya menghasilkan model prediksi yang akurat, tetapi juga menyajikannya melalui aplikasi web interaktif, memberikan wawasan berharga bagi pemangku kepentingan di pasar saham.

DAFTAR PUSTAKA

- [1] Budi. P, “Prediksi Harga Saham Syariah Menggunakan Algoritma Long Short-Term Memory (LSTM) , Jurnal Nasional Teknologi dan Sistem Informasi.” Jurnal Nasional Teknologi dan Sistem Informasi,
<https://teknosi.fti.unand.ac.id/index.php/teknosi/article/view/2142/0>. Accessed 17 June 2023.
- [2] P. T. Yamak, L. Yujian, and P. K. Gadosey, “A comparison between ARIMA, LSTM, and GRU for time series forecasting,” in ACM International Conference Proceeding Series, Association for Computing Machinery, Dec. 2019, pp. 49–55. doi: 10.1145/3377713.3377722
- [3] L. M. Rasdi Rere, M. I. Fanany, and A. M. Arymurthy, “Metaheuristic Algorithms for Convolution Neural Network,” *Comput. Intell. Neurosci.*, vol. 2016, 2016
- [4] “PT. Bank Central Asia Tbk [BBCA].” *IDNFinancials*,
<https://www.idnfinancials.com/id/bbca/pt-bank-central-asia-tbk>. Accessed 19 June 2023.
- [5] Merfin, M., & Oetama, R. S. (2019). Prediksi Harga Saham Perusahaan Perbankan Menggunakan Regresi Linear Studi Kasus Bank BCA Tahun 2015-2017. *Ultimatics: Jurnal Teknik Informatika*, 11(1), 11-15.
- [6] K. Cho, B. van Merriënboer, D. Bahdanau, and Y. Bengio, “On the Properties of Neural Machine Translation: EncoderDecoder Approaches,” *Proceedings of SSST-8, Eighth Workshop on Syntax*.